# Demanda de bicicletas e mobilidade urbana

**Relatório estatístico — MLAM**
Análise desenvolvida com uma base pública real do UCI Machine Learning Repository. A proposta é entender como condições climáticas se relacionam com o uso do sistema de bicicletas compartilhadas e se essas variáveis ajudam a identificar dias de alta demanda.

**Integrantes:** Diogo Chiaradia Santos (RM 570246); Gustavo Torres de Oliveira (RM 572952); Lucas Furquim Lima (RM 568690); Rafael Laprega Gontijo Magalhaes (RM 561975).

**Problema:** operadores de mobilidade precisam antecipar a procura para distribuir bicicletas e planejar a operação. A análise não afirma causalidade: ela mostra associações observadas na base.

**Base e tratamento.** Foram usados 731 registros diários, entre 2011 e 2012. A base contém temperatura, sensação térmica, umidade, vento e total de aluguéis. Não havia valores ausentes nas colunas utilizadas. As variáveis climáticas são normalizadas na própria base (0 a 1 aproximadamente), por isso as conclusões falam em aumento relativo, e não em graus Celsius.

Fonte: Fanaee-T e Gama, *Bike Sharing Dataset*, UCI Machine Learning Repository, DOI 10.24432/C5W894. Acesso em 08/11/2026. Arquivo original preservado em data/day.csv.

# 1. Probabilidade normal

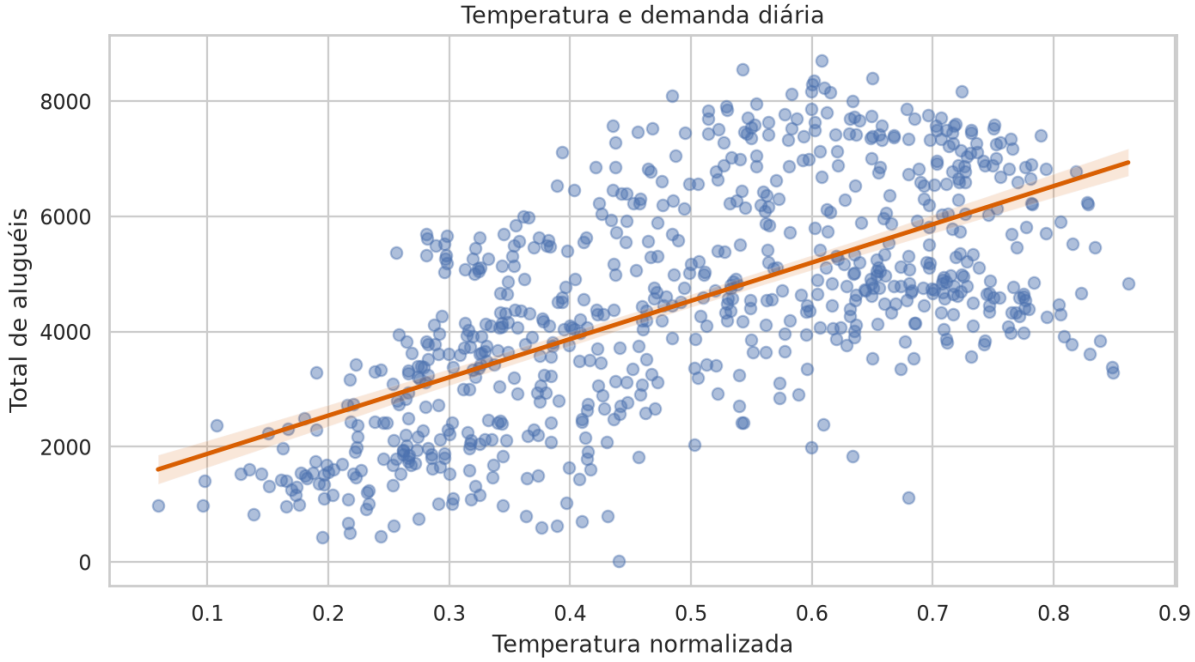
Escolhemos a temperatura normalizada. Média = 0,495; mediana = 0,498; desvio-padrão = 0,183. Sob a suposição normal, P(X < média) = 50,00%, um evento equiprovável. Para P(X > mediana), a aproximação normal resultou em 49,36%, também aproximadamente equiprovável, embora a mediana observada não seja exatamente igual à média.

# 2. Testes de hipótese para a média

Usamos como referência a média de toda a população observada e amostras aleatórias reproduzíveis. No teste unilateral à esquerda (n=20, $\alpha$=6%), média amostral = 0,476, z = -0,465, p = 0,3210: não rejeitamos H0. No teste unilateral à direita (n=25, $\alpha$=9%), média amostral = 0,523, z = 0,749, p = 0,2271: não rejeitamos H0. Como os testes usam a média da própria base como referência, eles funcionam como uma verificação didática, não como evidência de causalidade.

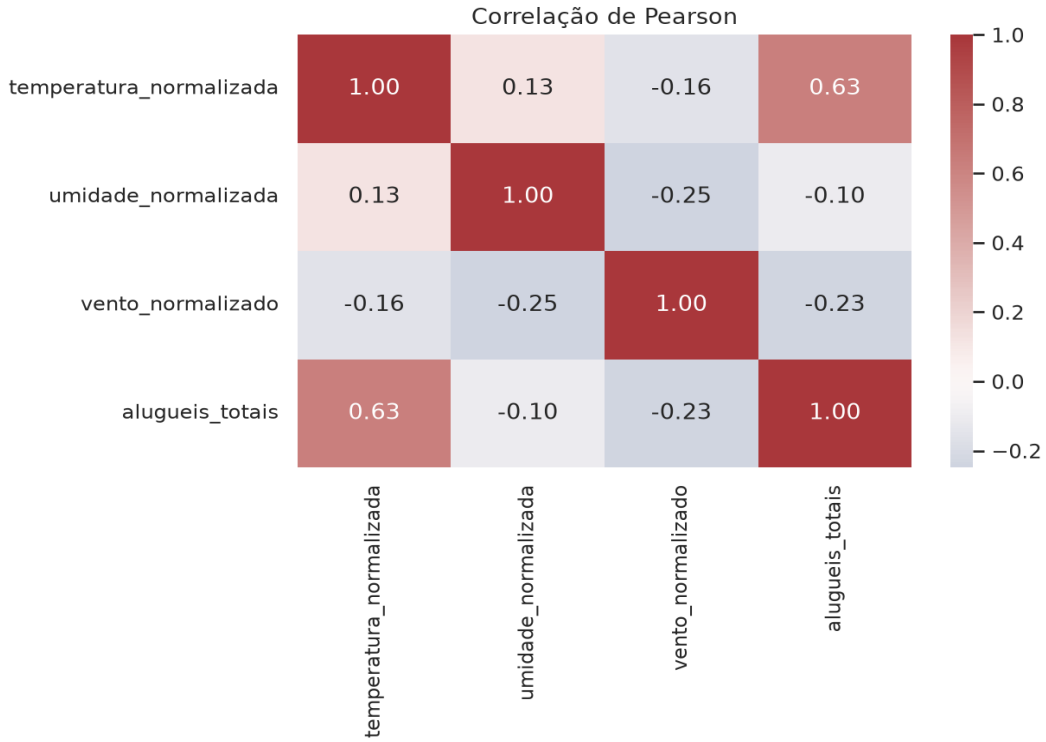
# 3. Análise bivariada

A relação entre temperatura e aluguéis totais foi positiva: covariância = 222,5147 e correlação de Pearson r = 0,627. O modelo linear simples estimou y = 1214.64 + 6640.71 × temperatura e explicou $R^2$ = 0,394 da variação observada. O teste F teve p = 0,00000, indicando associação estatisticamente detectável neste conjunto. Para uma temperatura normalizada de 0,70, a previsão do modelo é de aproximadamente 5.863 aluguéis. Ainda assim, o gráfico mostra dispersão: temperatura sozinha não basta para planejar a operação.


Temperatura e demanda diária
Total de aluguéis
8000
6000
4000
2000
0
0.1
0.2
0.3
0.4
0.5
0.6
0.7
0.8
0.9
Temperatura normalizada

# 4. Regressão linear múltipla

Incluímos temperatura, umidade e vento para explicar os aluguéis totais. A equação estimada foi: y = (6625.53 × temperatura_normalizada) + (-3100.12 × umidade_normalizada) + (-4806.93 × vento_normalizado) + (4084.36). O modelo alcançou $R^2$ = 0,461 ($R^2$ ajustado = 0,459) e teste F com p = 0,00000. Para um cenário com temperatura=0,70, umidade=0,55 e vento=0,20, a previsão é de 6.056 aluguéis. O $R^2$ indica que ainda há fatores importantes fora do modelo, como estação, feriados, dias úteis e tendência temporal.




## Matriz de covariância e correlação

| Variável | temperatura_normalizada | umidade_normalizada | vento_normalizado | alugueis_totais |
|---|---|---|---|---|
| temperatura_normalizada | 0,034 | 0,003 | -0,002 | 222,515 |
| umidade_normalizada | 0,003 | 0,020 | -0,003 | -27,773 |
| vento_normalizado | -0,002 | -0,003 | 0,006 | -35,212 |
| alugueis_totais | 222,515 | -27,773 | -35,212 | 3.752.788,208 |

## Matriz de correlação de Pearson

| Variável | temperatura_normalizada | umidade_normalizada | vento_normalizado | alugueis_totais |
|---|---|---|---|---|
| temperatura_normalizada | 1,000 | 0,127 | -0,158 | 0,627 |
| umidade_normalizada | 0,127 | 1,000 | -0,248 | -0,101 |
| vento_normalizado | -0,158 | -0,248 | 1,000 | -0,235 |
| alugueis_totais | 0,627 | -0,101 | -0,235 | 1,000 |

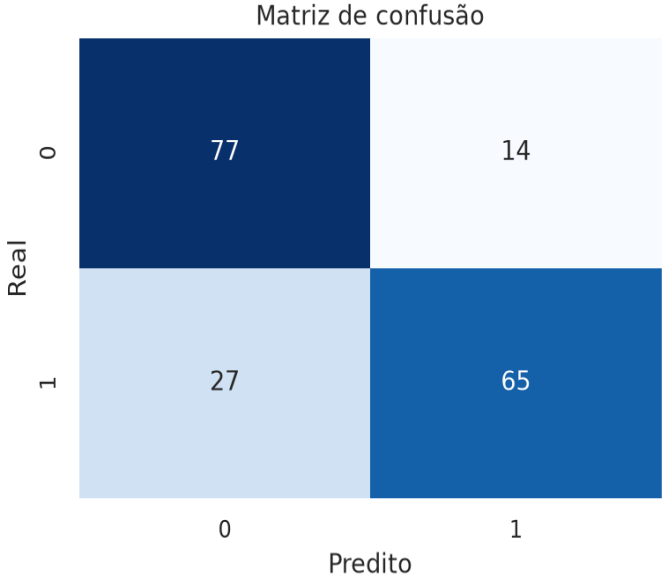
Na matriz de correlação, temperatura apresenta a associação linear mais evidente com a demanda entre as variáveis climáticas usadas. Correlação não significa que o clima, sozinho, cause o aumento: calendário e comportamento também participam do resultado.

# 5. Regressão logística binária

Criamos a classe **alta demanda** quando os aluguéis totais ficaram acima ou iguais à mediana (4.548). O modelo usa temperatura, umidade e vento. A acurácia no conjunto de teste foi 77,60%. A matriz de confusão foi TN=77, FP=14, FN=27 e TP=65. A classificação é útil como alerta operacional, mas não substitui uma

previsão completa, pois o corte pela mediana é uma escolha analítica.

Equação em logito: logit(p) = 0.024 + (1.481)·temperatura + (-0.720)·umidade + (-0.523)·vento




# 6. Conclusão e limitações

Os dados sugerem que dias mais quentes tendem a ter mais aluguéis: r=0,627 e $R^2$ simples=0,394. Ao combinar temperatura, umidade e vento, o $R^2$ passa a 0,461, mostrando ganho, mas também deixando claro que a maior parte da variação depende de outros fatores. A classificação de alta demanda atingiu 77,60% de acurácia. O próximo passo seria incorporar feriados, dias úteis, estação, chuva e tendência temporal, além de validar o modelo em um período futuro. Os resultados são associações da base e não devem ser tratados como causalidade ou garantia de demanda.